LSTAT2120: Linear Models

Objectif du projet :

analyser les principaux facteurs influençant la durée de sommeil afin de mieux comprendre les déterminants de ce comportement essentiel pour la santé et le bien-être.

Authors :
Devaux Nathan
Piron Louis-David

December 19, 2024

Contents

1 Objectifs **1**
1.1 Présentation du jeu de données 1
1.2 Data preprocessing 2

2 Analyse descriptive **3**
2.1 Aperçu des variables quantitatives 3
2.2 Aperçu des variables qualitatives 4

3 Exogénéité stricte **5**

4 Modèle et méthodologie **6**
4.1 Sélection du modèle 6
4.2 Vérifications des hypothèses classiques 8
4.3 Améliorations du modèle 11

5 Résultats **12**
5.1 Significativité des coefficients 12
5.2 Tests statistiques 13

6 Prédiction et validation **14**

7 Conclusion **15**

A Annexe **16**
A.1 Annexe 1 : Boxplots des variables 16
A.2 Annexe 2 : Calcul des VIFs 16
A.3 Annexe 3 : Approche '*Brute Force*' 17
A.4 Annexe 4 : *Stepwise Selection* 17
A.5 Annexe 5 : Méthode de LASSO 18
A.6 Annexe 6 : Hétéroscédasticité 19
A.7 Annexe 7 : *Outliers* 19
A.8 Annexe 8 : modèle réduit 20

1 Objectifs

Au travers de ce projet, notre objectif est d'identifier les principaux facteurs influençant **la durée de sommeil**, dans le but de mieux comprendre les éléments qui affectent cet aspect crucial de la santé et du bien-être.

Pour ce faire, nous développerons un modèle linéaire sur base d'un jeu de données reprenant des informations relatives au **mode de vie** et à l'**état de santé** de 374 individus. Nous consacrerons 90 % de ces données pour entraîner notre modèle, les 10 % restants serviront à évaluer sa performance.

1.1 Présentation du jeu de données

Notre jeu de données compte 374 individus et 13 variables (dont 4 catégorielles) liées au sommeil et aux habitudes de vie. Pour chaque individu, les variables suivantes ont été recensées :

- `Age`: l'âge, en années
- `Sleep.Duration`: la durée de sommeil, en heures/jour
- `Quality.of.Sleep`: une autoévaluation de la qualité de son sommeil, de 1 à 10
- `Physical.Activity.Level`: l'activité physique journalière, en minutes
- `Stress.Level`: une autoévaluation de son niveau de stress, de 1 à 10
- `Blood.Pressure`: la pression sanguine systolique et diastolique, en millimètres de mercure [mmHg]
- `Heart.Rate`: le rythme cardiaque, en battements par minute [BPM]
- `Daily.Steps`: le nombre de pas/jour
- `Gender`: indicatrice du genre biologique
- `Occupation`: indicatrice du métier
- `BMI.Category`: catégorie correspondant à l'indice de masse corporelle
- `Sleep.Disorder`: indicatrice d'un trouble du sommeil

Point théorique.

La tension est indiquée par la succession de deux nombres : la **pression systolique** et la **pression diastolique**. La pression systolique (PS) est la pression maximale, au moment de la "contraction" du cœur (systole). La pression diastolique (PD) est la pression minimale, au moment du "relâchement" du cœur (diastole).

Ces différentes métriques permettent d'évaluer si une personne souffre d'**hypotension** (PS < 90 et PD < 60) ou d'**hypertension**(PS > 140 et PD > 90).

1.2 Data preprocessing

Data cleaning

En examinant de plus près notre jeu de données, nous constatons que la variable `BMI.Category` comporte quatre niveaux : `Obese`, `Overweight`, `Normal` et `Normal.Weight`. Comme la littérature scientifique ne distingue pas entre `Normal` et `Normal.Weight`, nous supposons qu'il s'agit d'une erreur d'encodage et remplaçons `Normal.Weight` par `Normal`.

De manière similaire, pour la variable `Occupation`, nous observons que les vendeurs sont désignés soit comme `Salesman`, soit comme `Sales Representative`. Ces deux termes se référant au métier de vendeur, nous avons décidé de remplacer `Sales Representative` par `Salesman`.

Formatting

Pour faciliter notre analyse ultérieurement, nous effectuons quatre opérations :

- Séparer la variable `Blood.Pressure` en ses deux sous-composantes : pression diastolique (`Diastolic`) et pression systolique (`Sistolic`) ;
- Réorganiser l'ordre des variables en plaçant les variables quantitatives au début et les variables catégorielles à la fin ;
- Créer des nouvelles variables catégorielles où certaines catégories sont agrégées entre elles. Plus précisément, les catégories des variables `Occupation` et `Sleep.Disorder` seront traitées de la manière suivante :
  - Les catégories de la variable `Occupation` seront regroupées en quatre grandes catégories : `Business`[1], `Health`[2], `Technical`[3] et `Other` ;
  - La variable `Sleep.Disorder` sera simplifiée en `Yes` si l'individu est victime d'insomnies ou d'apnée du sommeil, et `No` sinon.
- Créer des *Dummy Variables* pour chacune de ces nouvelles catégories.

Ces transformations permettront de mieux structurer les données et d'assurer une meilleure interprétabilité du modèle utlérieurement.

[1] correspond aux comptables, managers et vendeurs
[2] correspond aux docteurs et infiermiers(ères)
[3] correspond aux ingénieurs et informaticiens

2 Analyse descriptive

2.1 Aperçu des variables quantitatives

	Moyenne	**Ecart-Type**	**Skewness**	**Kurtosis**
`Age`	42.18	8.67	0.26	-0.92
`Sleep.Duration`	7.13	0.80	0.04	-1.29
`Quality.of.Sleep`	7.31	1.20	-0.21	-0.77
`Physical.Activity.Level`	59.17	20.83	0.07	-1.27
`Stress.Level`	5.39	1.77	0.15	-1.33
`Systolic`	128.55	7.75	-0.04	-0.91
`Diastolic`	84.65	6.16	0.38	-0.86
`Heart.Rate`	70.17	4.14	1.22	2.21
`Daily.Steps`	6816.84	1617.92	0.18	-0.42

Table 1: Statistiques descriptives des variables quantitatives

En examinant la variable `Sleep.Duration` dans la Table 1. et dans les boxplots (*cf.* **Annexe 1**), nous constatons que la durée moyenne de sommeil des individus est de 7.13 heures, ce qui se situe dans la fourchette des recommandations pour un adulte en bonne santé [4]. La Skewness étant de 0.04, on observe une distribution relativement symétrique, avec 50% des individus ayant une durée de sommeil comprise entre 6.40 et 7.80 heures. La Kurtosis de -0.92 indique une distribution plus applatie que la Normale (*i.e.* des queues de distributions plus épaisses). Les valeurs extrêmes de 5.80 heures (minimum) et 8.50 heures (maximum) montrent que certains individus dorment un peu moins ou un peu plus que la moyenne, mais globalement, la majorité semble avoir un sommeil dans les normes.

Pour la variable `Quality.of.Sleep`, la moyenne est de 7.31 sur 10, indiquant une perception globalement positive du sommeil. L'écart-type de 1.20 montre une certaine variabilité dans les évaluations, tandis que la Skewness de -0.21 suggère une légère asymétrie vers des évaluations de qualité inférieures.

En ce qui concerne les autres variables, `Age` a une moyenne de 42.18 ans, avec un écart-type de 8.67, ce qui indique une population relativement diversifiée en termes d'âge. Les variables `Physical.Activity.Level` et `Daily.Steps` montrent une grande variabilité, avec un écart-type élevé de 20.83 et 1617.92 (respectivement), suggérant que certains individus sont beaucoup plus actifs que d'autres. Le `Stress.Level` présente une moyenne de 5.39, ce qui indique que les niveaux de stress sont modérés dans l'ensemble, avec une faible asymétrie, ce qui signifie que la distribution des niveaux de stress est relativement équilibrée. Les valeurs moyennes des pressions sanguines `Systolic` et `Diastolic` sont respectivement de 128.55 mmHg et 84.65 mmHg, ce qui les place légèrement au-dessus des valeurs normales [5]. Cela pourrait être dû par la présence d'individus présentant de l'hypertension. Le `Heart.Rate` moyen de 70.17 bpm est quant à lui tout à fait normal.

[4] Bulletin épidémiologique hebdomadaire (BEH), Santé publique France. 2019, Nos. 8-9. (p.153)
[5] Organisation Mondiale de la Santée (OMS),"Maîtrisez votre tension artérielle, maîtrisez votre vie"

Matrice des corrélations.

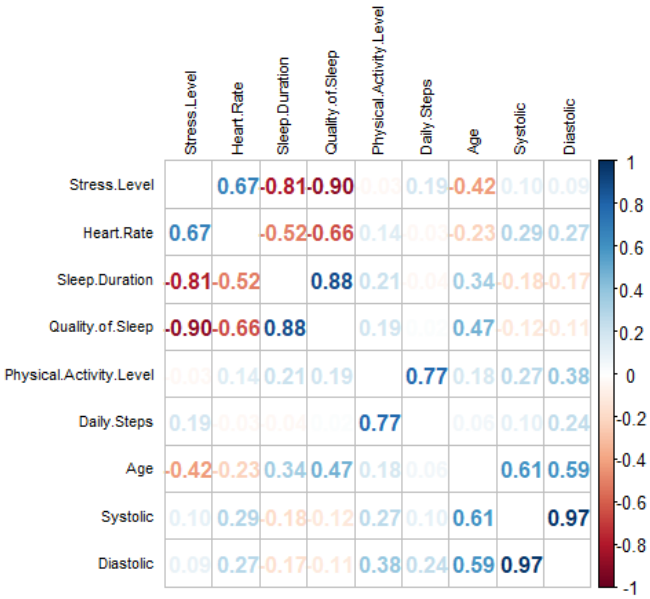

Figure 1: Matrice des corrélations.

Il convient de noter que certaines variables présentent des corrélations élevées entre elles. Par exemple, les variables `Quality.of.Sleep` et `Stress.Level` montrent une forte corrélation négative de -0.8988, ce qui suggère que la qualité du sommeil et le niveau de stress sont étroitement liés. De plus, les variables `Systolic` et `Diastolic` sont fortement corrélées (0.9729), ce qui est attendu, car elles mesurent deux aspects de la pression artérielle.

Bien que des corrélations élevées ne signifient pas automatiquement qu'il existe un problème de multicolinéarité, il est important de garder ces relations en tête. En effet, une forte multicolinéarité peut entraîner une instabilité dans l'estimation des coefficients du modèle linéaire, rendant l'interprétation plus complexe.

2.2 Aperçu des variables qualitatives

Sleep Disorder	Moyenne	Écart-type
Female	7.23	0.879
Male	7.04	0.693

Table 2: Durée de sommeil moyenne en fonction du genre biologique.

Nous remarquons que les hommes et les femmes présentent une durée de sommeille moyenne similaire, avec un écart-type plus grand pour les femmes.

Occupation Type	Moyenne	Écart-type
Business	6.76	0.44
Health	7.02	0.93
Other	7.08	0.44
Technical	7.81	0.74

Table 3: Durée de sommeille moyenne par occupation.

Les personnes dans le secteur des affaires (*Business*) ont la durée de sommeil la plus courte en moyenne (6.76 heures), avec un écart-type relativement faible indiquant une certaine uniformité au sein de cette catégorie.

BMI Category	Moyenne	Écart-type
Normal	7.39	0.72
Obese	6.96	0.88
Overweight	6.77	0.76

Table 4: Durée de sommeille moyenne en fonction de l'IMC.

Les individus ayant un indice de masse corporelle normal (*Normal*) ont une durée moyenne de sommeil de 7.39 heures, tandis que ceux classés comme obèses (*Obese*) ou en supoids (*Overweight*) dorment en moyenne moins (6.96 et 6.77 heures,respectivement).

Sleep Disorder	Moyenne	Écart-type
No	7.36	0.73
Yes	6.81	0.77

Table 5: Durée de sommeil moyenne en fonction de la présence de troubles du sommeil.

De manière évidente, les personnes sans trouble du sommeil (*No*) dorment en moyenne plus que celles ayant des troubles du sommeil (*Yes*).

3 Exogénéité stricte

L'hypothèse d'exogénéité stricte se formule comme suit : $\mathbb{E}[\varepsilon|X] = 0$. Elle implique à la fois $\mathbb{E}[\varepsilon] = 0$ et $\mathbb{C}ov(\varepsilon, X) = 0$. Cela signifie que les erreurs de régression ne doivent pas être corrélées avec les variables explicatives. Cependant, même pour notre modèle complet, il est plausible que certaines variables explicatives, comme `Stress.Level` ou `Quality.of.Sleep`, soient influencées par des facteurs non observés, ce qui pourrait créer une corrélation entre ces variables et les erreurs ($\mathbb{C}ov(\varepsilon, X) \neq 0$). Par exemple, des variables latentes comme les traits de personnalité, les événements de vie ou des conditions de santé non mesurées pourraient influencer à la fois ces variables indépendantes et la variable dépendante (`Sleep.Duration`), violant ainsi l'hypothèse d'exogénéité. De plus, la question de la causalité inverse (*reverse causality*) pourrait également violer cette hypothèse, car certaines variables explicatives pourraient être influencées par la variable indépendante (`Sleep.Duration`). Par conséquent, on peut raisonnablement conclure que l'exogénéité stricte ne tient probablement pas.

4 Modèle et méthodologie

4.1 Sélection du modèle

Nous avons choisi de nous appuyer sur les 3 méthodes de sélection vues en cours. Celle de Type I (*Brute Force*), de Type II (*Stepwise Selection*) et de Type III (LASSO).

Type I : *Best Subset Selection*

La méthode de Type I est une approche dite *brute force*, elle consiste à évaluer toutes les combinaisons possibles de variables explicatives. Pour chaque ensemble de P variables, il existe $\binom{P}{p}$ façons de sélectionner p variables. Autrement dit, en partant du principe que nous souhaitons un modèle avec au minimum une variable indépendante, nous avons $\sum_{p=1}^{P}\binom{P}{p}$ modèles possibles. Ainsi, pour notre base de données comportant 19 régresseurs possibles, la méthode de Type I reviendrait à évaluer $\sum_{p=1}^{19}\binom{19}{p} = 524,287$ modèles, ce qui est numériquement coûteux.

Cependant, pour éviter toute multicolinéarité, nous devons d'emblée désélectionner certaines variables. En effet, afin de ne pas tomber dans le *Dummy trap*, il est nécessaire de retirer une variable indicatrice pour chaque catégorie. Nous tombons donc à 15 variables et donc à $\sum_{p=1}^{15}\binom{15}{p} = 32,767$ modèles.

De plus, lors de l'analyse descriptive, nous avons observé que certaines variables étaient fortement corrélées. En calculant les *variance inflations factors* (VIFs), nos soupçons se confirment, une forte multicolinéarité est présente dans le modèle complet. Ceci nous mène à retirer `Diastolic`, qui possédait le VIF le plus élevé (107). Puis, `Quality.of.Sleep`, dont le VIF était de 18.89. Une fois ces deux variables enlevées, plus aucun VIF n'est supérieur à 10 (*cf.* **Annexe 2**). Nous tombons finalement à 10 variables et donc à $\sum_{p=1}^{13}\binom{13}{p} = 8,191$ modèles, ce qui est beaucoup moins numériquement couteux.

Il faut approximativement 2 minutes à `R` pour pacourir ces 8,191 modèles. Au terme de ce parcours, au moyen de la fonction `ols_step_best_subset()`, on est à même de voir que c'est le modèle à 11 variables suivant qui est le meilleur :

$$\texttt{Sleep.Duration} = \mathbf{X}\beta + \varepsilon \tag{I}$$

Où $\mathbf{X} = (\iota, \texttt{Age}, \texttt{Physical.Activity.Level}, \texttt{Stress.Level}, \texttt{Heart.Rate},$
$\texttt{Daily.Steps}, \texttt{Systolic}, \texttt{Gender_Male}, \texttt{Occupation_Type_Business},$
$\texttt{Occupation_Type_Health}, \texttt{Occupation_Type_Technical}, \texttt{BMI.Category_Normal})$

En effet, c'est ce modèle qui maximise le R_a^2 (0.8788), et qui minimise C_p (10.9348) et AIC (102.6307). Pour plus détails, *cf.* **Annexe 3**.

D'un point de vue prédictif, lorsque nous calculons la MSE du modèle sur les données du `validation_set`, nous obtenons une MSE de 0.1042667.

Type II : *Stepwise Selection*

Pour rappel, la ***Forward Selection*** commence avec un modèle simple (logique KISS[6]), puis ajoute les variables séquentiellement. À chaque étape, pour chaque variable candidate, on calcule un indice F_k qui mesure l'amélioration du modèle. La variable qui maximise cet indice et dont la p-valeur est inférieure à un seuil de signification (SLE) est ajoutée. Ce processus continue jusqu'à ce qu'aucune autre variable n'améliore le modèle de manière significative.

A contrario, la ***Backward Elimination*** commence avec un modèle complet, puis élimine les variables une par une en s'appuyant sur un indice F_k^* et un "seuil de stop" (STS), on parle alors de la logique GETS[7].

Dans le cadre de notre jeu de données, les deux méthodes renvoient le même modèle que celui trouvé en (I). Notons que, par extension, les modèles trouvés via *Forward Selection* et *Backward Elimination* ont eux aussi la même MSE (de 0.1042667). Pour plus de détails, *cf.* **Annexe 4**.

Type III : LASSO

La régression LASSO (*Least Absolute Shrinkage and Selection Operator*) est une technique de régularisation qui permet de sélectionner un sous-ensemble de variables tout en réduisant les autres coefficients à zéro. L'idée fondamentale derrière LASSO est d'ajouter une pénalité sur la somme des valeurs absolues des coefficients ($\lambda \sum_j |\beta_j|$) à la fonction de coût classique de la régression linéaire ($RSS = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$). Cette pénalité force certains coefficients à devenir exactement égaux à zéro, ce qui permet d'effectuer une sélection automatique des variables.

L'objectif principal de la régression LASSO est de minimiser la fonction suivante :

$$\text{Min}_\lambda \quad RSS + \lambda \sum_{j=1}^{p} |\beta_j|$$

où λ est le paramètre de régularisation (multiplicateur de Lagrange), qui détermine l'importance de la pénalité appliquée aux coefficients. Si λ est trop grand, le modèle devient trop simple (sous-ajustement), tandis que si λ est trop petit, le modèle peut devenir trop complexe et surajusté aux données d'entraînement.

Pour sélectionner la meilleure valeur de λ, on utilise le processus de *cross-validation*. Dans `R`, la fonction `cv.glmnet()` permet de réaliser cette technique, avec par défaut un choix de 10 groupes (on parle alors de *10-fold corss-validation*).

Lorsqu'on applique cette méthode à notre `training_set` et qu'on sélectionne le modèle correspondant au λ qui minimise la MSE, on retombre sur le modèle trouvé en (I). Voir détails en **Annexe 5**.

[6] "*Keep It Sophisticatelly Simple*"
[7] "*General To Specific*"

4.2 Vérifications des hypothèses classiques

Hypothèse de linéarité

Sur la Figure 2, nous remarquons que, dans l'ensemble, la plupart des relations étudiées montrent une structure approximativement linéaire. Toutefois, certaines variables ne semblent pas décrire une relation linéaire claire avec notre variable dépendante (*e.g.* `Daily.Steps` et `Systolic`). Cela peut sous-entendre que ces variables ne présentent pas de lien clair avec la variable dépendante, qu'un grand *signal/noise* ratio est présent, ou que la droite de régression à été influencée par des valeurs influentes (ce point en particulier sera abordé ultérieurement).

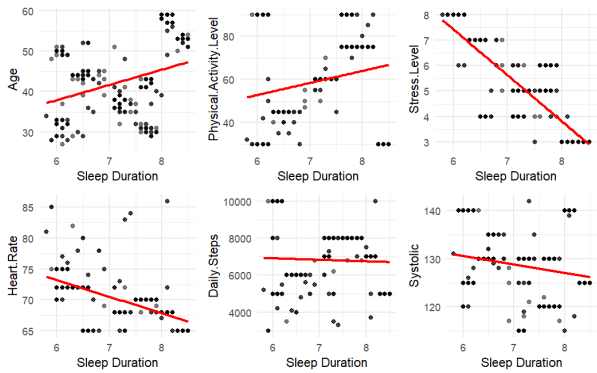

Figure 2: Nuages de points entre la variable dépendante (`Sleep.Duration`) et les différentes variables indépendantes sélectionnées plus haut. Une droite de régression en rouge est ajustée pour chaque couple de variables

Hypothèse d'homoscédasticité

Il est primordial de vérifier l'hypothèse d'homoscédasticité. En effet, une variance non constante des résidus peut compromettre la validité des tests statistiques et intervales de confiance. Si ignorée, l'hétéroscédasticité peut donc conduire à des conclusions erronées sur la significativité des coefficients estimés.

Une bonne pratique est de d'abbord regarder au *Scale-Location plot* :

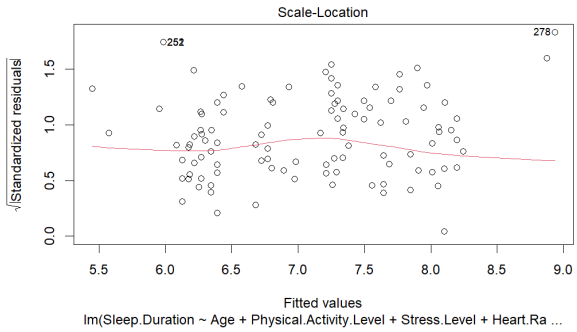

Figure 3: *Scale Location plot*

Une ligne rouge et des points répartis de manière homogène autour de cette dernière est un bon indicateur d'homoscédasticité.

Ici, il est difficile de dire si il y a oui ou non de l'hétéroscédasticité. Nous procédons donc à un test formel, le Test de White. Le test nous donne une p-valeur de $3.4e^{-30}$, on rejette donc l'hypothèse nulle d'absence d'hétéroscédasticité.

En observant la dispersion des résidus en fonction de chaque variable indépendante (*cf.* **Annexe 6**), nous remarquons que l'hétéroscédasticité pourrait être causée par les variables `Age`, `Daily.Steps`, `Occupation_Type_Business` et `Occupation_Type_Technical`, cela reste toutefois difficile à évaluer.

Pour résoudre ce problème, nous avons d'abord tenté d'introduire des **termes non linéaires**, sans succès. En effet, nous avons d'abord cherché à corriger l'hétéroscédasticité de notre modèle en modifiant les variables quantitatives [8] qui, selon nous, pouvaient être à la source du problème.

Plus particulièrement, nous avons travaillé sur la variable `Age`, que nous avons transformée en $\texttt{Age}^{-1}$. Ou encore `Sleep.Duration` et `Heart.Rate` en log(`Sleep.Duration`) et log(`Heart.Rate`). Bien que ces transformations aient eu un impact sur la dispersion des résidus (particulièrement pour `Age`), elles n'ont pas permis d'éliminer l'hétéroscédasticité.

Ensuite, nous avons essayé d'utiliser la méthode des *feasible weighted least squares* (FWLS). Pour ce faire, comme conseillé dans le cours, nous avons effectué la régression auxiliaire[9] du test de White, pour tenter de trouver des intéractions entre les résidus et les variables indépendantes. Nous avons ensuite utilisé les valeurs ajustées de ce même modèle comme des poids pour le modèle FWLS. Toutefois, l'hétéroscédasticité persiste. Pour pouvoir quand même utiliser les estimateurs OLS malgré l'hétéroscédasticité, nous nous penchons donc finalement vers l'inférence robuste, que nous aborderons plus en détail ultérieurement.

Hypothèse d'absence de valeurs influentes

Il est crucial de vérifier la présence d'observations influentes car l'estimation par OLS est sensible à ces dernières. En effet, elles peuvent fausser les coefficients de régression et donc par extension compromettre l'interprétation des résultats et réduire la fiabilité du modèle.

Pour vérifier si l'observation i est une valeur influente, la littérature scientifique recommande de vérifier si :

$$D_i > F_{p,n-p,0.5}$$

Où $D_i = \frac{e_i^2}{pMSE}\frac{h_{ii}}{(1-h_{ii})^2}$ est la distance de *Cook* et h_{ii} le *leverage*, qui corespond à l'i-ème élément de la diag$\{\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\}$.

[8] En effet, des transformations sur nos variables catégorielles binaires n'auraient pas de sens (*eg* avec la transformation $(\ldots)^{-1/2}$, $0^{-1/2} = \nexists, 1^{-1/2} = 1$)

[9] Regression des résidus au carré par rapport à tous les premiers et seconds moments des variables indépendantes.

Pour notre jeu de donnée, $F_{11,363,0.5} \approx 0.94$ et la plus grande distance de *Cook* est $D_{278} = 0.21$, qui est plus petit que 0.94. Il n'y a donc pas d'observations influentes dans notre jeu de données (Notons que l'absence de valeurs influentes n'implique pas l'absence d'*outliers*, pour d'informations à ce sujet,*cf* **Annexe 7**).

Hypothèse d'absence de multicolinéarité

La multicolinéarité peut avoir plusieurs conséquences négatives sur un modèle de régression linéaire. En particulier, les coefficients deviennent très sensibles aux petites variations dans les données. Et, les signes et les valeurs des coefficients peuvent être difficiles à interpréter ou incohérents.

Dans le cours, on considère qu'il y a un problème de multicolinéarité si le VIF maximum est supérieur à 10. Dans notre modèle, le VIF maximum obtenu est de 6.99, ce qui est inférieur au seuil critique de 10. On conclut donc qu'il n'y a pas de multicolinéarité significative dans les variables explicatives du modèle.

Hypothèse d'absence d'autocorrélation

Pour tester formelement la présence d'autocorélation, nous avons utilisé le test de Breusch-Godfrey où l'hypothèse nule est l'absence d'autocorrélation ($Corr(\varepsilon_i, \varepsilon_{i-1}) = 0$).

Le test de Breusch-Godfrey pour une autocorrélation jusqu'à l'ordre 2 donne un résultat pour lequel nous devons rejeter l'hypothèse nulle d'absence d'autocorrélation (p-valeur de $2.2e10^{-16}$). Nous avons donc une **autocorrélation significative des résidus** jusqu'à l'ordre 2 pour notre modèle[10]. Notons qu'une conséquence importante de l'autocorrélation est que l'estimateur OLS n'est plus **BLUE** (*Best Linear Unbiased Estimator*).

Bien que des méthodes existent pour traiter l'autocorrélation (FWLS, inférence corrigée par la matrice de covariance estimée de Newey-West, *etc*), le fait que notre modèle soit pourvu également d'hétérosédasticité ne nous laisse plus qu'une seule possibilité : l'inférence robuste à l'autocorrélation et à l'hétéroscédasticité (en utilisant l'estimateur HAC[11] de la matrice de variance-covariance).

Hypothèse de Normalité des résidus

Un bon moyen pour avoir une première idée de la distribution des résidus est de regarder au QQ-plot (*Quantile-Quantile plot* des résidus standardisés (*cf.* Figure 4).

Lorsque les points s'alignent approximativement le long de la diagonale, cela indique que les résidus sont proches de suivre une distribution normale. Dans notre cas, comme les résidus sont concentrés autour de la droite, on suspecte qu'ils suivent bel et bien une distribution Normale.

[10] résidus du modèle linéaire sont corrélés avec eux-mêmes à des décalages successifs, jusqu'à 2 observations (e_i avec e_{i-1} **et** e_{i-2}).

[11] *Heteroskedasticity- & Autocorrelation-Consistent.* On retrouve cet estimateur via la fonction `vcovHAC()` du package `sandwich`.

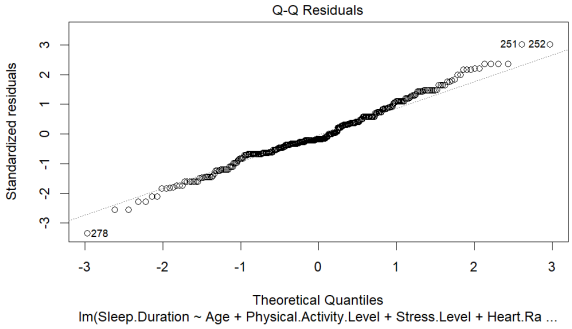

Figure 4: QQ-plot des résidus standardisés

Plus formellement, nous pouvons utiliser le test de Jarque-Bera, où l'hypothèse nulle est la Normalité des résidus ($S = 0, \kappa = 3$). Sous H_0 :

$$JB \sim \chi^2_2$$

Où $JB = \frac{n}{6}\left(S^2 + \frac{(\kappa-3)^2}{4}\right)$

Appliqué aux résidus de notre modèle, le test de Jarque-Bera donne une statistique $JB = 3.2821$ avec une p-valeur $= 0.1938$. Puisque cette p-value est supérieure au seuil usuel de 5%, nous ne rejetons pas l'hypothèse nulle de Normalité.

4.3 Améliorations du modèle

Comme spécifié au cours des dernières pages, nous avons exploré plusieurs approches pour tenter de résoudre les problèmes identifiés dans notre modèle, comme l'estimation via la méthode des FWLS ou différentes transformations de variables. Ces méthodes ne s'étant pas montrées fructueuses, nous nous sommes donc rabattus sur l'inférence HCA.

En situation réelle, afin d'améliorer notre modèle, une solution évidente serait de revoir la spécification de notre modèle. Dans le cas présent, cette solution impliquerait l'introduction de nouvelles variables explicatives et présupposerait l'accès aux individus pour lesquels nous avons les mesures/indicateurs. Si c'était le cas, nous proposerions l'ajout de nouvelles variables expliquant la variable `Sleep.Duration`, telles que : *le temps d'écran avant d'aller dormir* ou la *consommation de caféine ou théine en soirée*. On pourrait également prendre en compte des facteurs environnementaux, tels que le *niveau de bruit dans la chambre*, la *luminosité de la pièce* ou encore la *température ambiante*. Ces variables additionnelles pourraient apporter des informations supplémentaires et, de ce fait, résoudre certains des problèmes qui ont été soulevés sans avoir recours à l'inférence HCA.

5 Résultats

5.1 Significativité des coefficients

```
> coeftest(brute_force,vcovHAC(brute_force))
t test of coefficients:
                            Estimate  Std. Error t value  Pr(>|t|)
(Intercept)                8.3427e+00  1.6432e+00  5.0770 6.469e-07 ***
Age                        4.5096e-02  9.1251e-03  4.9420 1.241e-06 ***
Physical.Activity.Level    7.8805e-03  3.7464e-03  2.1035 0.0361894 *
Stress.Level              -3.3456e-01  3.8979e-02 -8.5829 3.878e-16 ***
Heart.Rate                 2.8578e-02  1.7923e-02  1.5944 0.1118114
Daily.Steps               -5.6127e-05  4.6699e-05 -1.2019 0.2302751
Systolic                  -3.0667e-02  1.1157e-02 -2.7486 0.0063199 **
Gender_Male                4.7604e-01  6.4806e-02  7.3456 1.665e-12 ***
Occupation_Type_Business  -1.6176e-01  1.3142e-01 -1.2308 0.2192744
Occupation_Type_Health     2.5285e-01  9.9100e-02  2.5514 0.0111851 *
Occupation_Type_Technical  1.1558e-01  1.1258e-01  1.0267 0.3053467
BMI.Category_Normal        3.7268e-01  9.5354e-02  3.9083 0.0001131 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

Le coefficient de `Age` est positif (0.045), ce qui indique qu'une augmentation de l'âge est associée à une légère augmentation de la durée du sommeil. Cela pourrait traduire des besoins physiologiques croissants liés à l'âge. Le coefficient de `Physical.Activity.Level` est également positif (0.00788), suggérant que des niveaux plus élevés d'activité physique sont associés à une durée de sommeil plus longue. Cela pourrait refléter l'idée que l'exercice favorise un meilleur sommeil et/ou crée un besoin accru de récupération. À l'inverse, `Stress.Level` a un coefficient négatif (-0.3345), indiquant qu'une augmentation du stress entraîne une diminution significative de la durée du sommeil. Le coefficient de `Systolic` (-0.0307) montre une relation négative avec la durée du sommeil. Cela pourrait refléter l'impact négatif de l'hypertension sur le sommeil.

En ce qui concerne les variables qualitatives, `Gender_Male` a un coefficient positif (0.476), ce qui indique que les hommes dorment en moyenne 28 minutes de plus que les femmes, toutes choses égales par ailleurs. `Occupation_Type_Health` a un coefficient positif (0.253), cela pourrait s'expliquer parles régimes de travail irréguliers dans ce secteur, où un sommeil plus long est nécessaire pour compenser la fatigue liée à des horaires de travail stressants ou à des nuits de garde. `BMI.Category_Normal` montre un coefficient positif (0.373), suggérant que les personnes ayant un IMC normal dorment plus longtemps que celles ayant un IMC plus élevé.

En ce qui concerne les variables non significatives, telles que `Heart.Rate`, `Daily.Steps`, `Occupation_Type_Business`, et `Occupation_Type_Technical`, cela signifie que, à elles seules, ces variables ne permettent pas de prédire de manière fiable la durée du sommeil dans le cadre de ce modèle. Les p-values associées à ces coefficients sont supérieures au seuil de significativité habituel (0.05), ce qui suggère qu'elles n'ont pas d'impact significatif sur la variable dépendante dans ce contexte. Toutefois, cela ne signifie pas nécessairement qu'elles sont inutiles ; elles pourraient notamment interagir avec d'autres variables.

A noter que l'intercept représente la durée de sommeil moyenne estimée pour une personne de sexe féminin, travaillant dans la catégorie `Occupation_Type_Other`, sans activité physique, sans stress, et sans autres facteurs influents.

5.2 Tests statistiques

Test d'un ensemble de coefficients.

Nous avons échangé les points 8 et 7 pour voir s'il était possible de reduire notre modèle en enlevant certaines variables individuellement non significatives identifiée au point précédent.

Pour l'hypothèse nulle : H_0 : `Occupation_Type_Technical` = `Daily.Steps` = 0, le test F fournit une statistique de test de 1.1087 et un p-valeur de 0.3312. Étant donné que cette valeur est supérieure au seuil de significativité de 0.05, nous ne rejetons pas l'hypothèse nulle. Cela signifie qu'il n'y a pas de preuve suffisante pour affirmer que `Occupation_Type_Technical` et `Daily.Steps` influencent la durée du sommeil. Comme, ces variables ne semblent pas apporter une information significative dans la modélisation de la durée du sommeil, nous pouvons donc réduire notre modèle (ce qui nous mène au modèle présenté en **Annexe 8**).

Test d'une combinaison linéaire d'au moins deux coefficients.

Tester une combinaison linéaire permet de vérifier si une relation proportionnelle ou pondérée existe entre plusieurs variables. Cela aide notamment à explorer s'il y a des interdépendances pertinentes qui mériteraient d'être modélisées plus explicitement.

Nous avons testé l'hypothèse linéaire suivante :

$$-0.05 \times \texttt{Age} - 0.37 \times \texttt{Stress.Level} + 0.04 \times \texttt{Heart.Rate} = 0$$

Les résultats du test montrent que cette hypothèse est rejetée de manière hautement significative ($F = 67.087$, p-valeur $= 6.014e10^{-15}$). Cela indique que la combinaison linéaire spécifiée des coefficients des variables `Age`, `Stress.Level`, et `Heart.Rate` contribue significativement à expliquer `Sleep.Duration`.

Ce rejet suggère que ces trois variables, considérées conjointement dans les proportions spécifiées par leurs coefficients, ont un effet significatif sur la durée de sommeil. L'importance du test confirme que les contributions combinées de ces facteurs ne peuvent pas être négligées et qu'elles jouent un rôle clé dans la dynamique du modèle.
En pratique, cela valide l'idée que l'interaction entre l'âge, le niveau de stress, et la fréquence cardiaque influence significativement la durée de sommeil, avec des implications potentielles pour les interventions ciblées sur ces facteurs dans un contexte de santé et bien-être.

6 Prédiction et validation

Les intervalles de prédiction fournissent une estimation de la plage dans laquelle une nouvelle observation tombera avec une probabilité donnée.

Dans notre cours, nous avons défini l'intervalle de prédiction pour un *nominal level* de $(1-\alpha)100\%$ comme étant donné par :

$$\hat{Y}_h \pm t_{n-p;1-\alpha/2} \cdot S \left\{ x_h^\top \left(\mathbf{X}\mathbf{X}^\top \right)^{-1} x_h \right\}^{-1/2}$$

Dans notre cas, l'intervalle de prédiction de `Sleep.Duration` ressemble à ceci :

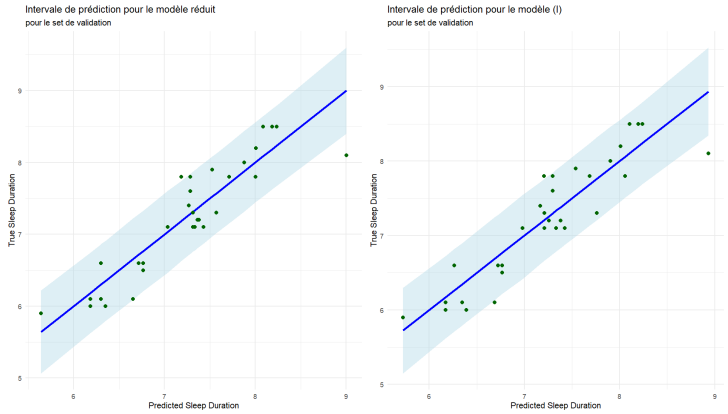

Figure 5: Intervale de prédiction au niveau nominal de 95 % pour les modèles réduit (à gauche) et initial (à droite).

Le calcul de la couverture des intervalles de prédiction de `Sleep.Duration` pour le **modèle initial** a donné une couverture de 91,89 %, légèrement inférieure au niveau nominal de 95 %. Cela pourrait indiquer que le modèle initial capture non seulement le signal des données du `training_set`, mais aussi leur bruit spécifique (on parle alors d'*overfitting*).

Notons qu'avec un jeu de validation de petite taille (37 observations), ils est possible que des fluctuations aléatoires viennent affecter la couverture observée. Enfin, la présence d'*outliers* dans le `validation_set`pourrait fausser les prédictions et réduire la fiabilité des intervalles également.

En comparaison, le **modèle réduit** présente une couverture de 94,6 %, beaucoup plus proche du niveau nominal de 95 %. Cette meilleure performance peut être attribuée au fait que le modèle réduit est moins susceptible de surapprendre et donc généralise mieux sur le jeu de validation. En se concentrant uniquement sur les variables les plus pertinentes, il fournit des intervalles de prédiction plus réalistes et capture mieux l'incertitude totale. Cela se reflète également dans la MSE légèrement plus faible de 0.1037, contre 0.1043 pour le modèle initial.

7 Conclusion

L'objectif principal de ce projet était de développer un modèle linéaire afin d'identifier les facteurs clés influençant la durée du sommeil. En s'appuyant sur les différentes méthodes de sélection et d'analyse vue en cours, nous avons pu construire un modèle avec une certaine efficacité prédictive.

Ce modèle révèle l'influence significative de variables telles que l'âge, le niveau d'activité physique, le stress et le genre. Par exemple, une augmentation du niveau de stress diminue de manière marquée la durée du sommeil, tandis qu'un mode de vie actif contribue positivement à une meilleure récupération. Les individus ayant un IMC normal semblent également bénéficier d'une durée de sommeil plus longue que ceux en surpoids ou obèses. De manière plus inattendue, notre analyse a montré que les personnes travaillant dans le secteur de la santé dorment en moyenne davantage, ce qui pourrait être lié à une activité professionnelle intense nécessitant un repos compensateur accru. Ces résultats mettent en lumière la diversité des déterminants du sommeil et soulignent leur potentiel pour des applications concrètes en santé publique.

En outre, ce projet nous a offert l'occasion précieuse d'appliquer les outils statistiques vus en cours à un contexte réel. Nous avons appris à gérer et prétraiter des données, à sélectionner des modèles appropriés et à interpréter des résultats de manière critique. Cette expérience nous a également fait prendre conscience qu'il est souvent bien plus difficile en pratique de satisfaire pleinement les hypothèses classiques des modèles linéaires. En effet, les données peuvent se montrer récalcitrantes.

Malgré ces potentielles limites, telles que l'hétéroscédasticité et l'autocorrélation des résidus, nous avons vu qu'il était quand même possible d'interpréter les estimateurs OLS au moyen de l'inférence HAC. L'intégration de nouvelles variables explicatives, telles que le temps d'écran, la consommation de caféine ou encore les conditions environnementales comme le bruit et la luminosité de la chambre, pourrait également s'avérer utile.

En conclusion, ce projet nous offre un outil analytique pour mieux comprendre les comportements de sommeil et les facteurs qui les influencent. Il constitue une base pertinente pour développer des stratégies d'intervention ciblées visant à améliorer la qualité du sommeil et, par conséquent, le bien-être général de la population.

A Annexe

A.1 Annexe 1 : Boxplots des variables

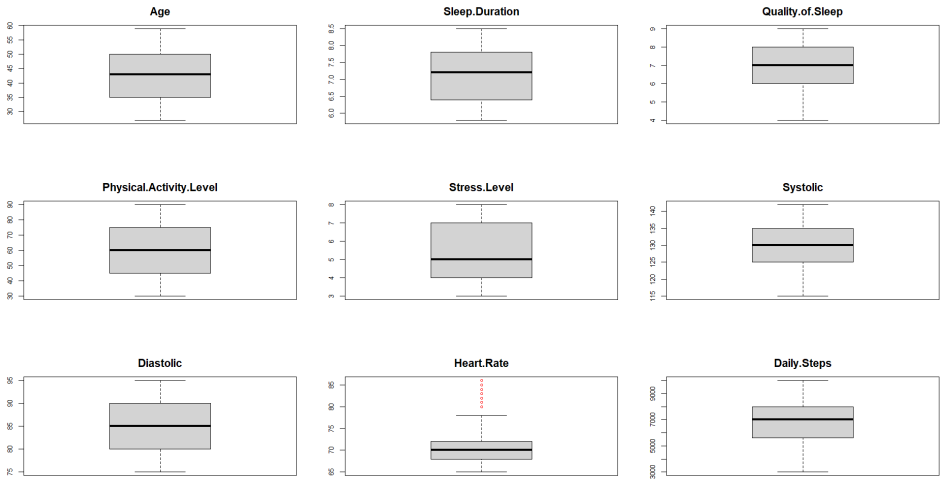

Figure 6: Boxplots des variables quantitatives

A.2 Annexe 2 : Calcul des VIFs

VIFs du modèle complet, en ayant enlevé une catégorie par variable catégorielle :

```
                     Age          Quality.of.Sleep   Physical.Activity.Level
               12.677687                 19.227953                  5.755997
            Stress.Level                Heart.Rate               Daily.Steps
               18.005349                  6.572775                  6.982817
               Diastolic                  Systolic               Gender_Male
              107.001067                 92.826327                  2.900453
Occupation_Type_Business    Occupation_Type_Health Occupation_Type_Technical
                3.273931                  3.461143                  2.510670
      BMI.Category_Normal        BMI.Category_Obese        Sleep.Disorder_Yes
                9.829594                  2.950631                  3.618925
```

VIFs après avoir enlevé `Diastolic` :

```
                     Age          Quality.of.Sleep   Physical.Activity.Level
               10.007976                 18.895765                  5.720540
            Stress.Level                Heart.Rate               Daily.Steps
               17.035787                  6.512380                  5.525221
                Systolic               Gender_Male  Occupation_Type_Business
                7.738089                  2.673212                  3.270517
   Occupation_Type_Health Occupation_Type_Technical       BMI.Category_Normal
                2.407610                  2.486884                  6.589236
       BMI.Category_Obese        Sleep.Disorder_Yes
                2.591377                  3.511464
```

VIFs après avoir enlevé `Quality.of.Sleep` :

```
                     Age   Physical.Activity.Level              Stress.Level
                5.384758                  5.628801                  7.063134
               Heart.Rate               Daily.Steps                  Systolic
                6.504465                  5.496792                  7.611831
              Gender_Male  Occupation_Type_Business    Occupation_Type_Health
                2.276336                  3.269047                  2.391552
Occupation_Type_Technical       BMI.Category_Normal        BMI.Category_Obese
                2.387384                  4.866024                  2.589644
       Sleep.Disorder_Yes
                3.376575
```

A.3 Annexe 3 : Approche '*Brute Force*'

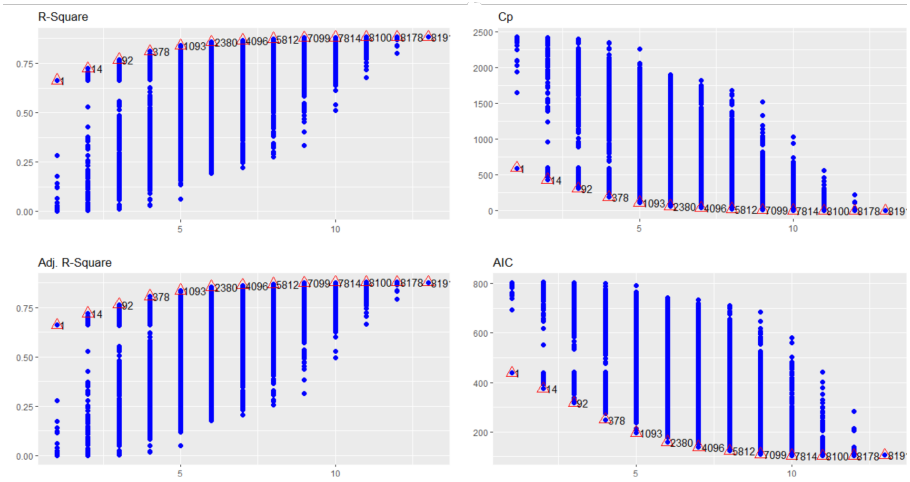

Figure 7: Chaque point bleu représente un des 8191 modèle de régression estimé. Les triangles rouge représentent le modèle idéal pour chaque nombre de variable et chaque critère de sélection.

En regardant de plus près aux meilleurs modèles trouvés pour un nombre p de régresseurs, nous remarquons que c'est le modèles à 11 variables qui est le plus performant :

Model	Adj. R-Square	Pred. R-Square	C(p)	AIC
1	0.6634	0.6624	596.7593	437.9580
2	0.7229	0.7213	434.3215	374.3678
3	0.7678	0.7657	312.2919	316.7824
4	0.8110	0.8088	194.9533	249.3919
.....				
8	0.8729	0.8698	31.9715	123.6456
9	0.8787	0.8754	17.9648	109.9146
10	0.8813	0.8777	12.8988	104.7297
11	0.8827	0.8788	10.9348	102.6307
12	0.8830	0.8787	12.1337	103.7964
13	0.8831	0.8784	14.0000	105.6569

A.4 Annexe 4 : *Stepwise Selection*

Forward selection :

Step	Variable	AIC	...	R2	Adj. R2
0	Base Model	802.909	...	0.00000	0.00000
1	Stress.Level	437.958	...	0.66341	0.66240
2	BMI.Category_Normal	374.368	...	0.72294	0.72128
3	Age	316.782	...	0.76784	0.76575
4	Gender_Male	249.392	...	0.81104	0.80876
5	Occupation_Type_Health	196.558	...	0.83942	0.83699
6	Heart.Rate	158.838	...	0.85727	0.85467
7	Systolic	138.529	...	0.86641	0.86357
8	Physical.Activity.Level	123.646	...	0.87294	0.86984
9	Occupation_Type_Technical	109.915	...	0.87873	0.87540
10	Daily.Steps	106.643	...	0.88062	0.87695
11	Occupation_Type_Business	102.631	...	0.88273	0.87876

Backward elimination :

Step	Variable	AIC	...	R2	Adj. R2
0	Full Model	105.657	...	0.88307	0.87836
1	BMI.Category_Obese	103.796	...	0.88302	0.87869
2	Sleep.Disorder_Yes	102.631	...	0.88273	0.87876

Notez que les 2 méthodes de *stepwise selection* mènent effectivement au même modèle que celui trouvé plus haut, avec le même AIC, le même R^2 et le même R_a^2.

A.5 Annexe 5 : Méthode de LASSO

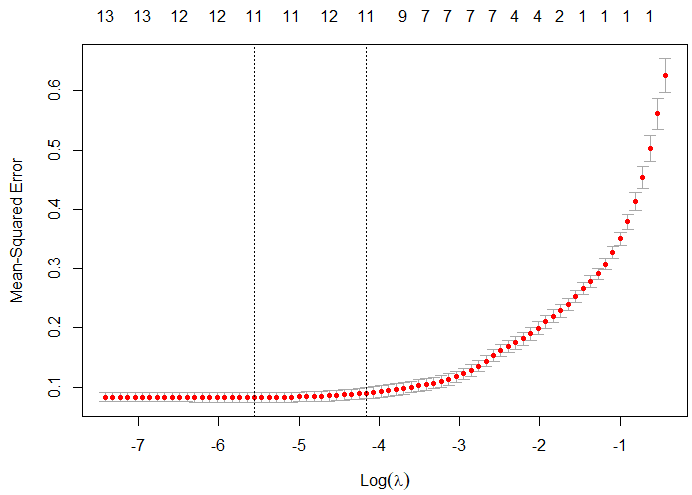

Figure 8: Courbe d'erreur quadratique moyenne en fonction de $\log \lambda$ pour la régression LASSO avec sélection par *10-fold cross validation*.

Ce graphique permet de choisir le paramètre de régularisation λ, et par conséquent le nombre de régresseurs p, qui minimise la MSE. Le graphique montre 2 lignes verticales :

- L'une à $\log 0.0039 \approx -5.55$, correspondant à la valeur $\lambda_{min} = 0.0039$ qui minimise la MSE.
- L'autre à $\log 0.016 \approx -4.16$, correspondant La valeur $\lambda_{1SE} = 0.016$, la valeur de λ la plus grande pour laquelle l'erreur est proche de la minimale dans un écart-type

Nous avons choisi le modèle associé à λ_{min}, qui est celui sélectionnant 11 régresseurs (*cf* axe horizontal supérieur).

Un rapide coup d'oeil aux sorties `R` associées au λ qui minimise la MSE montre que ce modèle à 11 régresseurs est identique à celui sélectionné via nos autres stratégies de sélection :

```
                              s1
(Intercept)                8.0762879900
Age                        0.0404267153
Physical.Activity.Level    0.0072031632
Stress.Level              -0.3356173672
Heart.Rate                 0.0242275832
Daily.Steps               -0.0000454951
Systolic                  -0.0249662410
Gender_Male                0.4448061567
Occupation_Type_Business  -0.1110035325
Occupation_Type_Health     0.2586276463
Occupation_Type_Technical  0.1424664699
BMI.Category_Normal        0.3857617788
BMI.Category_Obese         .
Sleep.Disorder_Yes         .
```

A.6 Annexe 6 : Hétéroscédasticité

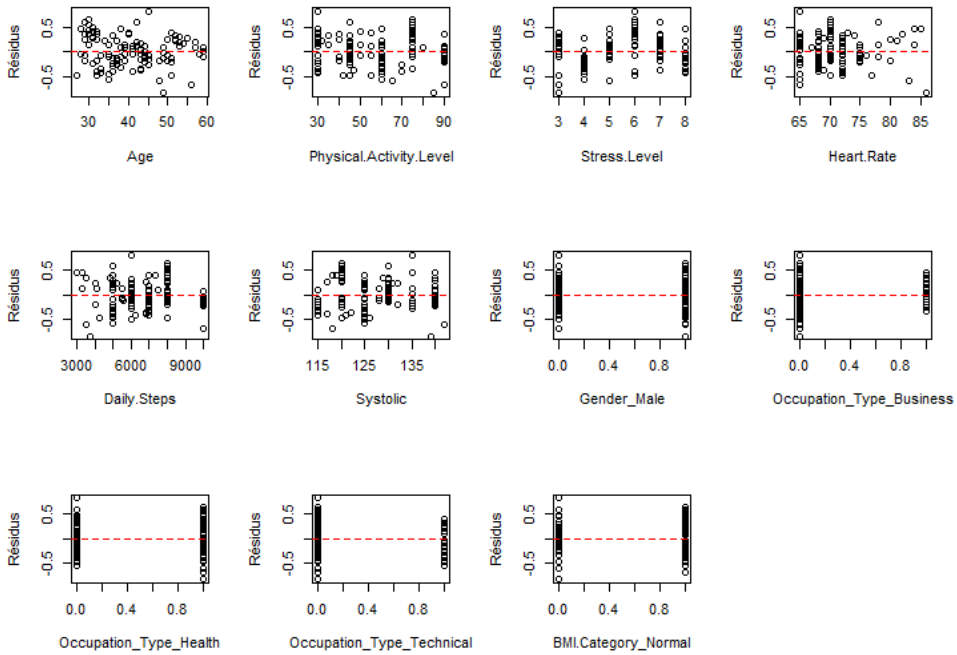

Figure 9: Résidus du modèle en fonction de chaque variable indépendante. Une ligne pointillée rouge est dessinée à 0, là où les résidus sont sensés être centrés.

A.7 Annexe 7 : *Outliers*

Outliers with respect to X

Nous savons qu'une observation X_i est considérée comme *outlier* si $h_{ii} > 2p/n$.En se basant sur ce critère, nous trouvons les valeurs aberrantes suivantes :

```
> rownames(dataset[which(leverage > (2*p)/n),])
 [1] "1"   "2"   "3"   "4"   "5"   "6"   "15"  "17"  "29"  "30"  "44"
[12] "45"  "60"  "61"  "72"  "73"  "78"  "79"  "80"  "81"  "82"  "84"
[23] "126" "128" "145" "160" "161" "179" "180" "222" "237" "239" "249"
[34] "307" "308"
```

Outliers with respect to Y

Nous savons qu'une observation Y_i est considérée comme *outlier* si $|d_i^*| > t_{n-p-1;1-\alpha/2n}$.En se basant sur ce critère, nous ne trouvons aucune valeur abérante par rapport à Y.

A.8 Annexe 8 : modèle réduit

Le modèle obtenu suite à la suppression des variables `Occupation_Type_Technical` et `Daily.Steps` est le suivant :

```
t test of coefficients:

                           Estimate Std. Error  t value  Pr(>|t|)
(Intercept)               7.4724551  1.3612859   5.4893 8.109e-08 ***
Age                       0.0490649  0.0072097   6.8054 4.823e-11 ***
Physical.Activity.Level   0.0037189  0.0019339   1.9230 0.0553484 .
Stress.Level             -0.3687485  0.0285515 -12.9152 < 2.2e-16 ***
Heart.Rate                0.0438213  0.0112662   3.8896 0.0001216 ***
Systolic                 -0.0329889  0.0100863  -3.2707 0.0011874 **
Gender_Male               0.5275329  0.0636567   8.2872 3.033e-15 ***
Occupation_Type_Business -0.2210865  0.0990545  -2.2320 0.0262941 *
Occupation_Type_Health    0.2059211  0.0854216   2.4106 0.0164756 *
BMI.Category_Normal       0.3813587  0.0972443   3.9217 0.0001072 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

Notons que pour ce modèle, les même hypothèses sont respectées (absence de multicolinéarité, Normalité des résidus, absence de valeurs influentes) et violées (hétéroscédasticité et autocorrélation) [12].

Ce modèle possède un AIC de 110.74, le plaçant légèrement en dessous de notre modèle initial (I) ayant un AIC de 102.63. Cependant, d'un point de vue prédictif, ce modèle semble plus performant. Sa MSE, pour le `validation_set` est de 0.1037, ce qui est légèrement inférieur à celle du modèle initial (0.1043). De plus, son *coverage percentage* est de 0.946, bien plus proche du niveau nominal de 0.95.

[12] Les tests ci-dessus ont donc été réalisé sur base d'une matrice de variance-covariance HAC.