LSTAT 2190 Concepts et traitement de vecteurs aléatoires: Projet B

Nathan Devaux
Noma : 40852100

December 2024

Résolution analytique

Ex1

Définission des paramètres de la fonction

Comme donné dans l'énoncé, les paramètres donnés pour la loi normale multivariée sont :

- **Vecteur des moyennes** :
$$\mu = (\mu_1, \mu_2, \mu_3) = \left(-2, \frac{5}{4}, 0.408\right)$$
- **Matrice de covariance** :
$$\Sigma = \begin{bmatrix} 1.28 & 0.61 & 0.36 \\ 0.61 & 1.31 & -0.61 \\ 0.36 & -0.61 & 0.88 \end{bmatrix}$$

Résolution

Pour (X_1, X_2), les paramètres marginaux sont :

$$\mu_{\text{marginal}} = \begin{bmatrix} -2 \\ 1.25 \end{bmatrix}, \quad \Sigma_{\text{marginal}} = \begin{bmatrix} 1.28 & 0.61 \\ 0.61 & 1.31 \end{bmatrix}.$$

Résultats pour les moyennes et covariances empiriques

- Moyennes empiriques :
$$\bar{x}_1 = -1.952, \quad \bar{x}_2 = 1.237$$
- Moyennes théoriques :
$$\mu_1 = -2, \quad \mu_2 = 1.25$$
- Matrice de covariance théorique :
$$\Sigma_{\text{marginal}} = \begin{bmatrix} 1.28 & 0.61 \\ 0.61 & 1.31 \end{bmatrix}$$
- Matrice de covariance empirique :
$$\Sigma_{\text{empirique}} = \begin{bmatrix} 1.251 & 0.675 \\ 0.675 & 1.264 \end{bmatrix}$$

Ex2

Si X_1 et X_2 sont des partitions de $X \sim \mathcal{N}_p(\mu, \Sigma)$, alors la distribution conditionnelle de X_2 donnée $X_1 = x_1$ est également normale.

Distribution conditionnelle de X_3 sachant (X_1, X_2)

La distribution conditionnelle de X_3 donnée (X_1, X_2) suit :

$$X_3 \mid (X_1 = x_1, X_2 = x_2) \sim \mathcal{N}(\mu_3(x_1, x_2), \sigma^2_{3|1,2}),$$

où :

$$\mu_3(x_1, x_2) = \mu_3 + \Sigma_{3,12}\Sigma_{12}^{-1}\begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix},$$

$$\sigma^2_{3|1,2} = \sigma_{33} - \Sigma_{3,12}\Sigma_{12}^{-1}\Sigma_{12,3}.$$

Résolution

Matrice de covariance entre X_3 et (X_1, X_2) :

$$\Sigma_{3,12} = \begin{bmatrix} 0.36 & -0.61 \end{bmatrix}.$$

Sous-matrice de covariance de (X_1, X_2) :

$$\Sigma_{12} = \begin{bmatrix} 1.28 & 0.61 \\ 0.61 & 1.31 \end{bmatrix}.$$

Inverse de Σ_{12} :

$$\Sigma_{12}^{-1} = \begin{bmatrix} 1.004 & -0.468 \\ -0.468 & 0.981 \end{bmatrix}.$$

Espérance conditionnelle :

$$\mu_3(x_1, x_2) = 0.408 + \begin{bmatrix} 0.647 & -0.767 \end{bmatrix}\begin{bmatrix} x_1 + 2 \\ x_2 - 1.25 \end{bmatrix}.$$

$$\mu_3(x_1, x_2) = 2.66 + 0.647x_1 - 0.767x_2.$$

Pour $x_1 = 1$, cela devient :

$$\mu_3(1, x_2) = 3.307 - 0.767x_2.$$

Variance conditionnelle:

$$\sigma^2_{3|1,2} = 0.151$$

Interprétation

L'espérance conditionnelle $\mu_3(x_1, x_2)$ décrit comment X_3 varie en fonction de X_1 et X_2. Pour $X_1 = 1$, elle devient une fonction linéaire de X_2, où chaque changement de une unité dans X_2 entraîne une variation de -0.767 dans l'espérance conditionnelle de X_3. Dans mes sorties R, dans lequelles je compare les moyennes théoriques et empiriques, on remarque que les deux valeurs sont à chaque fois très proches l'une de l'autre.

Ex3

La corrélation partielle mesure la relation entre deux variables, ici X_1 et X_3, en tenant compte de l'effet de la variable X_2. Elle est donnée par la formule suivante :

$$\rho_{13|2} = \frac{\rho_{13} - \rho_{12} \cdot \rho_{23}}{\sqrt{(1 - \rho_{12}^2)(1 - \rho_{23}^2)}},$$

où :

- ρ_{13} est la corrélation entre X_1 et X_3,
- ρ_{12} est la corrélation entre X_1 et X_2,
- ρ_{23} est la corrélation entre X_2 et X_3.

Résolution

- La matrice de covariance est donnée par :

$$\Sigma = \begin{bmatrix} 1.28 & 0.61 & 0.36 \\ 0.61 & 1.31 & -0.61 \\ 0.36 & -0.61 & 0.88 \end{bmatrix}$$

Les corrélations inconditionnées sont calculées comme suit :

$$\rho_{ij} = \frac{\Sigma_{ij}}{\sqrt{\Sigma_{ii} \cdot \Sigma_{jj}}}.$$

Calculs numériques

- $\rho_{12} = \frac{0.61}{\sqrt{1.28 \cdot 1.31}} = 0.471,$
- $\rho_{13} = \frac{0.36}{\sqrt{1.28 \cdot 0.88}} = 0.34,$
- $\rho_{23} = \frac{-0.61}{\sqrt{1.31 \cdot 0.88}} = -0.57.$

La corrélation partielle entre X_1 et X_3 sachant X_2 est alors :

$$\rho_{13|2} = \frac{0.34 - (0.471 \cdot -0.57)}{\sqrt{(1 - 0.471^2)(1 - (-0.57)^2)}}.$$

En simplifiant :

$$\rho_{13|2} = 0.836$$

Résultats

- Corrélation inconditionnée (ρ_{13}) :
$$\rho_{13} = 0.34$$
- Corrélation conditionnée ($\rho_{13|2}$) :
$$\rho_{13|2} = 0.836$$

Interprétation

La corrélation inconditionnée $\rho_{13} = 0.34$ capture la relation directe entre X_1 et X_3, sans tenir compte de l'effet de X_2.

En revanche, la corrélation conditionnée $\rho_{13|2} = 0.836$ montre la relation entre X_1 et X_3 après avoir contrôlé l'effet de X_2. On observe que la corrélation partielle est plus élevée que la corrélation inconditionnée, ce qui indique que X_2 joue un rôle dans la relation entre X_1 et X_3. Cela confirme également que X_2 n'est pas indépendant de X_1 et X_3, car les corrélations diffèrent.

Part 2: Copulas

Ex1

Paramètres de la distribution

Les paramètres donnés pour la distribution normale bivariée sont :

- Moyenne de X : $\mu_X = 0$,
- Moyenne de Y : $\mu_Y = 2$,
- Variance de X : $\sigma_X^2 = 1$,
- Variance de Y : $\sigma_Y^2 = 2$,

- Corrélation entre X et Y : $\rho_{XY} = -0.001 \cdot 408 = -0.408$.

La matrice de covariance Σ est calculée comme :

$$\Sigma = \begin{bmatrix} \sigma_X^2 & \rho_{XY} \cdot \sigma_X \cdot \sigma_Y \\ \rho_{XY} \cdot \sigma_X \cdot \sigma_Y & \sigma_Y^2 \end{bmatrix}.$$

Les paramètres sont donc:

$$\Sigma = \begin{bmatrix} 1 & -0.577 \\ -0.577 & 2 \end{bmatrix}.$$

Ex2

Paramètres empiriques

Les approximations empiriques des paramètres, calculées sur $n = 10,000$ réalisations, sont les suivantes :

- Moyenne empirique de X : $\mu_X \approx -0.0135$,
- Moyenne empirique de Y : $\mu_Y \approx 1.996$,
- Variance empirique de X : $\sigma_X^2 \approx 0.998$,
- Variance empirique de Y : $\sigma_Y^2 \approx 2.013$,
- Corrélation empirique entre X et Y : $\rho_{XY} \approx -0.412$.

Ces résultats montrent que les paramètres empiriques sont très proches des valeurs théoriques.

Visualisation des données

Le graphique suivant présente un diagramme de dispersion des données simulées, montrant la relation entre X et Y.

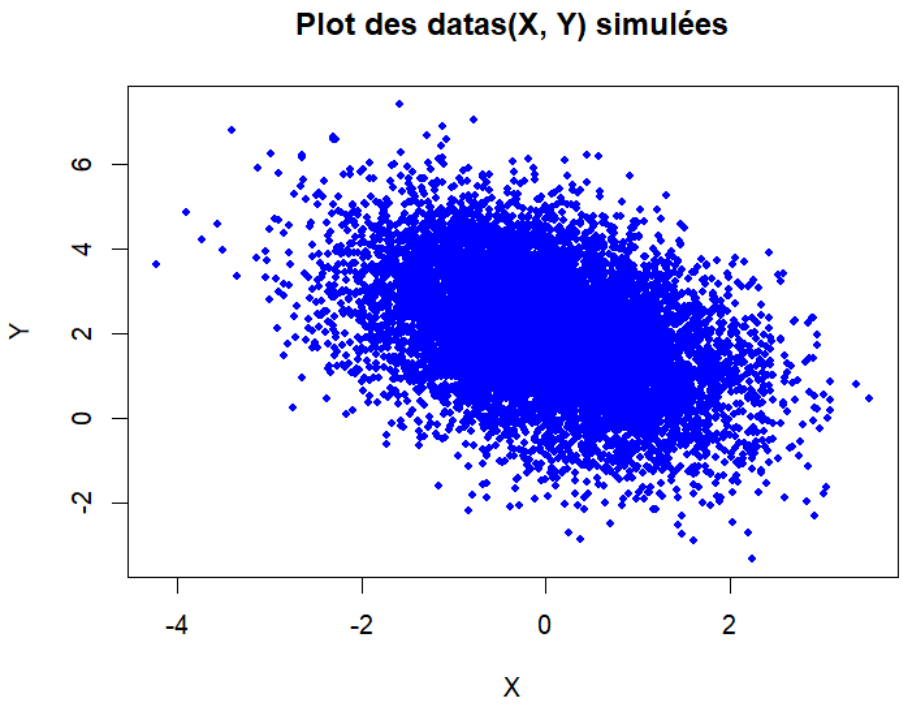

Interprétation : Le graphique nous montre une corrélation négative entre X et Y, conformément à la valeur théorique $\rho_{XY} = -0.408$.

Ex3

Pour répondre à cette question, nous avons utilisé une copule de Clayton avec différents paramètres θ.

1. Après avoir repris les données de l'exercice 1 :

$$X \sim \mathcal{N}(0,1), \quad Y \sim \mathcal{N}(2,2).$$

2. La copule de Clayton a été utilisée pour introduire une dépendance entre X et Y, paramétrée par θ. Les valeurs de θ choisies étaient 0.1 (faible dépendance), 1 (dépendance modérée) et 5 (forte dépendance).

3. Les données bivariées ont été générées pour chaque valeur de θ, puis transformées en fonction des distributions marginales de X et Y.

Visualisation

Le graphique suivant montre les relations entre X et Y pour les trois valeurs de θ :

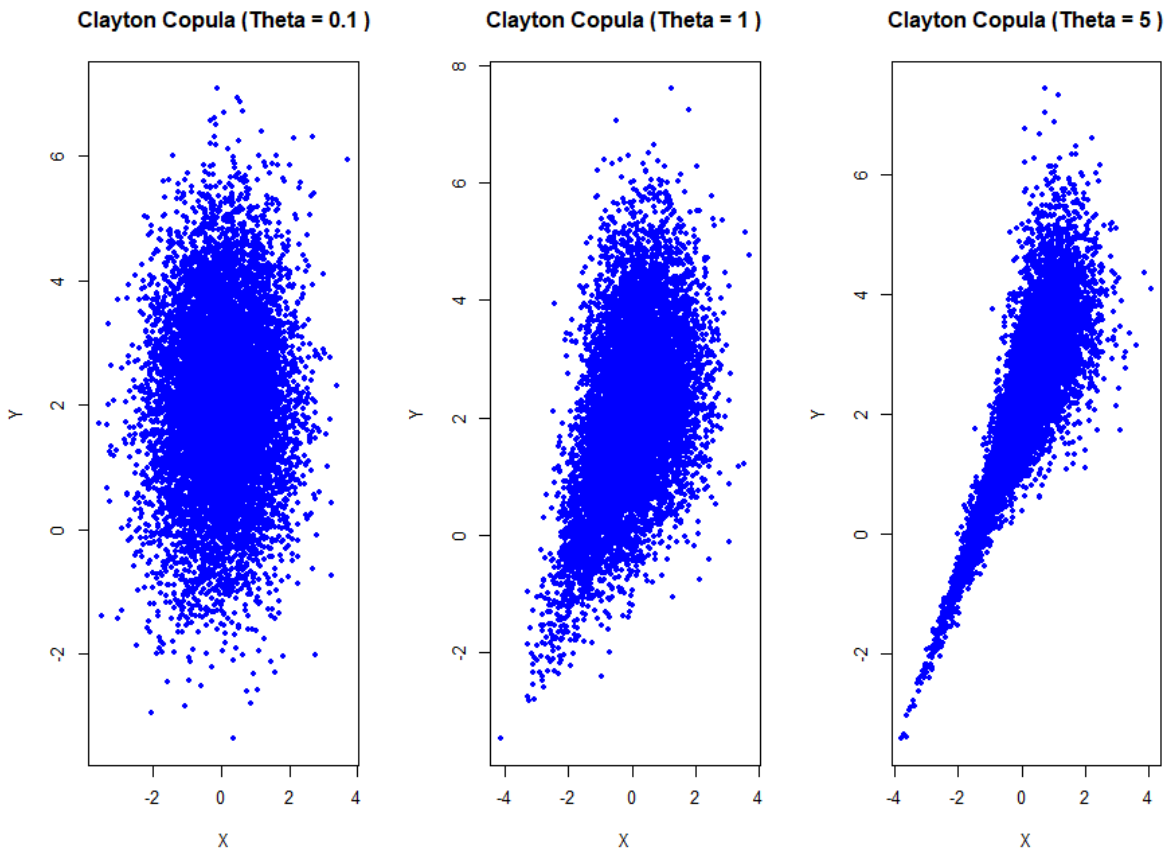

Interprétation

Les données générées illustrent comment la dépendance entre X et Y varie en fonction de θ :

- **Pour des valeurs faibles de θ (e.g., $\theta = 0.1$) :** La dépendance entre X et Y est très faible. Le nuage de points est dispersé. On ne remarque pas de relation spéciale entre les variable.
- **Pour des valeurs moyennes de θ (e.g., $\theta = 1$) :** On observe une légère dépendance. Le nuage de points commence à se resserrer, au plus les valeurs diminuent.
- **Pour des valeurs élevées de θ (e.g., $\theta = 5$) :** La dépendance est forte. Les points sont concentrés, indiquant une forte relation entre X et Y.

Ces observations montrent que la copule de Clayton permet de modéliser efficacement différents niveaux de dépendance entre les variables tout en conservant leurs distributions marginales.

Ex4

Dépendance des données originales

Pour les données originales (X, Y), les mesures de dépendance calculées sont :

- **Spearman's rho :** $\rho_S = -0.279$,
- **Kendall's tau :** $\tau_K = -0.188$,
- **Pearson's rho :** $\rho_P = -0.292$.

Ces résultats montrent une faible dépendance négative linéaire et monotone entre X et Y. Les trois mesures (ρ_S, τ_K, ρ_P) sont cohérentes entre elles.

Dépendance des données générées par la copule de Clayton

Pour les données générées à l'aide de la copule de Clayton, les mesures de dépendance varient en fonction de θ :

- **Pour $\theta = 0.1$:**
$$\rho_S = 0.0706, \quad \tau_K = 0.0472, \quad \rho_P = 0.074$$
La dépendance est très faible, ce qui est attendu pour des valeurs de θ proches de zéro, où la copule tend à une indépendance entre X et Y.
- **Pour $\theta = 1$:**
$$\rho_S = 0.470, \quad \tau_K = 0.326, \quad \rho_P = 0.488$$
Une dépendance modérée est observée. Les mesures montrent une relation positive monotone, avec une corrélation linéaire significative.
- **Pour $\theta = 5$:**
$$\rho_S = 0.886, \quad \tau_K = 0.716, \quad \rho_P = 0.862$$
La dépendance est très forte, avec une concentration des points près de la diagonale, comme le montrent également les mesures de dépendance.

Interprétation

Pour des valeurs faibles de θ, la dépendance entre X et Y est presque inexistante, ce qui se traduit par des mesures proches de zéro. Lorsque θ augmente, les relations monotones (mesurées par ρ_S et τ_K) deviennent plus fortes, ainsi que la corrélation linéaire (ρ_P). Les valeurs de Spearman et Kendall montrent une meilleure capacité à capturer les relations monotones globales, tandis que Pearson est limité à la corrélation linéaire.

Ces observations sont cohérentes avec la théorie de la copule de Clayton, où θ contrôle directement le niveau de dépendance asymétrique, en particulier dans les queues inférieures de la distribution.

Ex5

Dépendance des données générées avec des marges exponentielles

Après avoir remplacé les marges normales par des marges exponentielles, les mesures de dépendance obtenues pour les différentes valeurs de θ sont les suivantes :

- **Pour $\theta = 0.1$:**
$$\rho_S = 0.0659, \quad \tau_K = 0.044, \quad \rho_P = 0.0459$$
La dépendance est très faible, similaire à celle observée avec les marges normales. Les mesures indiquent une faible relation entre X et Y.
- **Pour $\theta = 1$:**
$$\rho_S = 0.484, \quad \tau_K = 0.338, \quad \rho_P = 0.296$$
Une dépendance modérée est observée. Les valeurs des trois mesures montrent une relation significative entre les variables, bien qu'elles soient légèrement réduites par rapport aux marges normales.

- **Pour $\theta = 5$:**

$$\rho_S = 0.8852, \quad \tau_K = 0.714, \quad \rho_P = 0.670$$

La dépendance est forte. Les mesures de Spearman et Kendall restent élevées, capturant la relation monotone, tandis que la corrélation de Pearson (ρ_P) est légèrement plus faible, en raison des caractéristiques non linéaires des marges exponentielles.

Interprétation

Les résultats montrent que, même avec des marges exponentielles, la copule de Clayton continue de modéliser efficacement la dépendance entre les variables. Voici les observations principales :

La dépendance augmente avec θ, comme attendu, que ce soit pour des marges normales ou exponentielles. Les mesures de dépendance (Spearman's rho et Kendall's tau) capturent bien la relation monotone induite par la copule, tandis que la corrélation linéaire de Pearson (ρ_P) est légèrement plus faible en raison de la nature asymétrique des marges exponentielles. Par rapport aux marges normales, les mesures de dépendance sont légèrement réduites pour les marges exponentielles, car celles-ci introduisent une asymétrie qui affecte les dépendances globales.

Ces résultats confirment que la dépendance mesurée par la copule est principalement influencée par θ, tandis que les marges modifient la structure spécifique des relations entre X et Y.

Ex6

Pour $\theta = 0$, la copule de Clayton correspond à une indépendance parfaite entre les deux variables. Les mesures de dépendance calculées à partir des données générées sont :

- **Spearman :** $\rho_S = -0.000294$,
- **Kendall :** $\tau_K = -0.000238$,
- **Pearson :** $\rho_P = 0.0031$.

Ces résultats confirment que les variables X et Y sont statistiquement indépendantes. Toutes les mesures de dépendance sont proches de zéro, comme attendu dans un contexte d'indépendance.

Visualisation

Le graphique suivant illustre la relation entre X et Y pour $\theta = 0$:

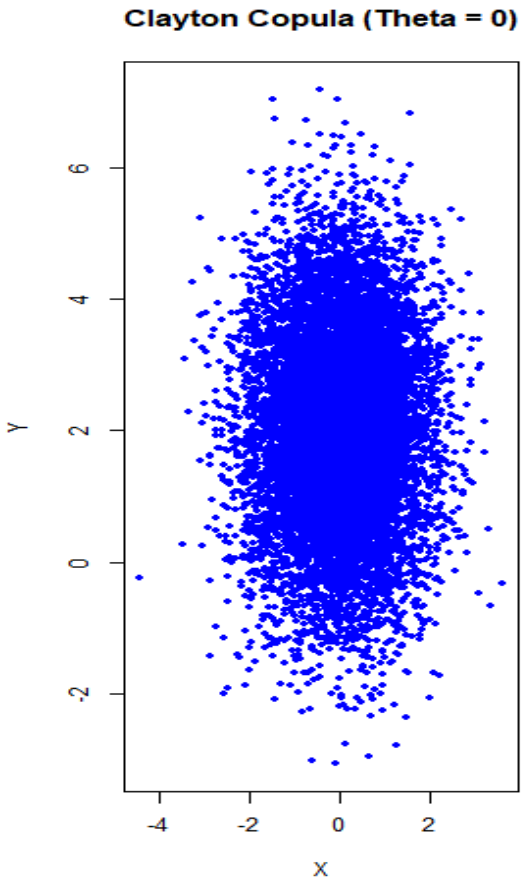

Interprétation

Les résultats montrent que, pour $\theta = 0$, la copule de Clayton devient une copule d'indépendance. Cela signifie qu'il n'y a aucune dépendance entre X et Y. Les observations principales sont les suivantes :

- Les mesures de dépendance (Spearman, Kendall, Pearson) sont toutes proches de zéro, indiquant une absence de relation monotone ou linéaire entre les variables.
- Le graphique montre un nuage de points uniformément réparti, sans structure apparente ou concentration, ce qui confirme l'indépendance visuelle des variables.

Ces observations sont cohérentes avec la théorie des copules et valident que, pour $\theta = 0$, la copule de Clayton ne modèle aucune dépendance entre les deux variables.